Carlos Augusto Amador Manilla
A01329447

# Testing two resampling methods or classifiers for solving class imbalance problems

Para esta tarea se extrajeron características adicionales de los tweets:

- Cantidad de menciones que contiene el tweet (numérica).
- Es retweet o no (nominal).
- Cantidad de ligas que contiene el tweet (numérica).
- Cantidad de palabras que contiene el tweet (numérica).

En primer lugar se probó con el clasificador Random Forest que mejor resultados había obtenido, agregando una característica a la vez. Se comprobó que cada característica mejoraba los resultados.

Con estas nuevas características se realizaron las pruebas con dos algoritmos de remuestreo y dos metaclasificadores sensibles al costo, utilizando como base el clasificador Random Forest previamente mencionado.

## Spread subsample

Utilizado para generar una muestra aleatoria del dataset, probé con diferentes valores para la distribución de clases, desde distribución uniforme hasta distribucion 2:1.

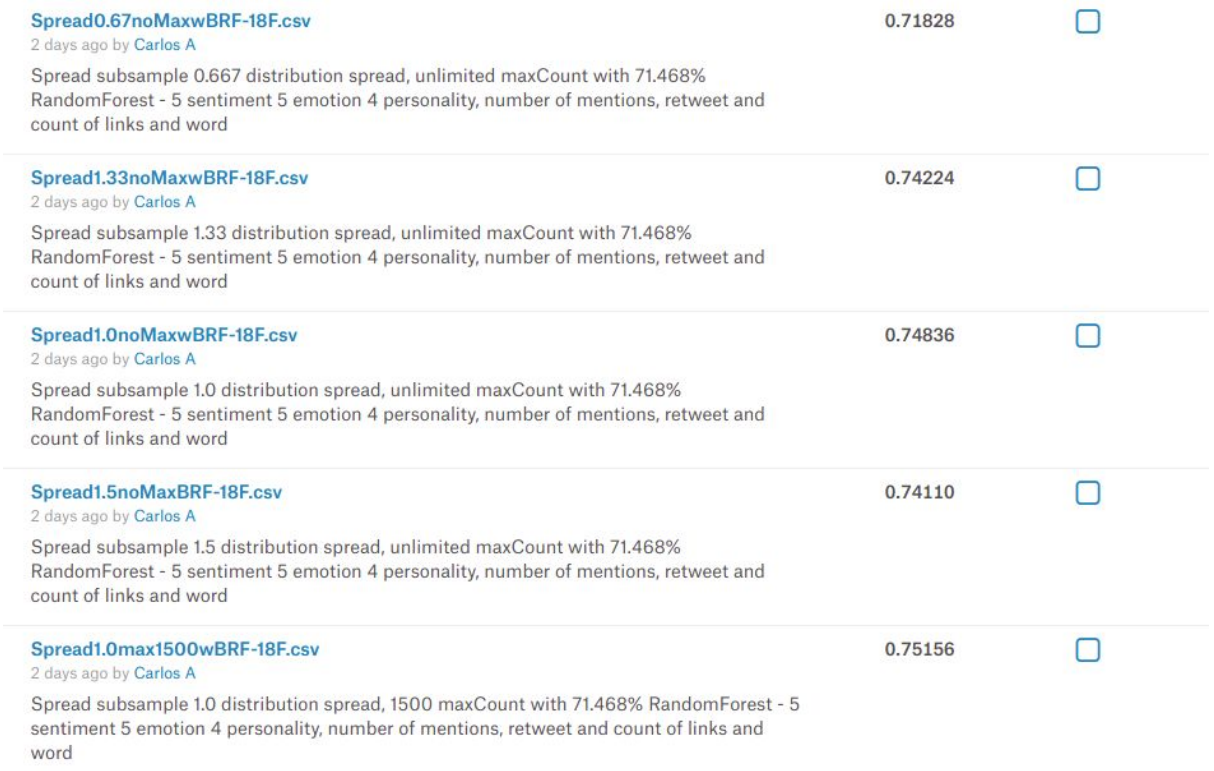


Tener mayor distribución de humanos obtuvo mejores resultados.

Carlos Augusto Amador Manilla
A01329447

# SMOTE

Genera nuevos datos de la clase minoritaria con información de k de sus vecinos más cercanos. Se utilizó para generar más instancias de la clase human.


Al igual que con Spread Subsample, se obtuvieron mejores resultados al generar más instancias de la clase minoritaria.

Carlos Augusto Amador Manilla
A01329447

# MetaCost

Hace a un clasificador sensible al costo, combina sensibilidad al costo con Bagging. Se comenzó castigando los falsos positivos por 1.667 aproximadamente el valor del desbalance y se continuó experimentando con otros costos.

**Meta-1.85C75BSP10I-18.csv** 0.74403
a day ago by Carlos A
MetaCost 75 BagSizePercent, [0, 1, 1.85, 0] matrix, 20 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**Meta-1.85C50BSP10I-18.csv** 0.73971
a day ago by Carlos A
MetaCost 50 BagSizePercent, [0, 1, 1.85, 0] matrix, 20 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**Meta-1.85C50BSP10I-18.csv** 0.73971
a day ago by Carlos A
MetaCost 50 BagSizePercent, [0, 1, 1.85, 0] matrix, 20 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**Meta-1.85C100BSP10I-18.csv** 0.74845
a day ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 1.85, 0] matrix, 100 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**Meta-1.75C100BSP10I-18.csv** 0.74168
a day ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 1.75, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**Meta-2.0C100BSP10I-18.csv** 0.74442
a day ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 2, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**Meta-1.5C100BSP10I-18.csv** 0.73819
a day ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 1.5, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**Meta-1.66C100BSP10I-18.csv** 0.74787
a day ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 1.667, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

Carlos Augusto Amador Manilla
A01329447

# Cost sensitive classifier

Hace al clasificador base sensible al costo.

**CS-1.66wRF-18F.csv** 0.75483
an hour ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 1.66, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**CS-1.75wRF-18F.csv** 0.76029
an hour ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 1.75, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**CS-1.5wRF-18F.csv** 0.75455
an hour ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 1.5, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

**CS-2.0wRF-18F.csv** 0.75692
an hour ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 2, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word

# Conclusiones

Atender el problema de desbalanceo produjo un incremento en la eficacia del clasificador, favorecer a la clase minoritaria -castigando falsos positivos y generando más instancias de la misma- sin duda ayudó a obtener mejores resultados.

El mayor puntaje lo obtuvo CostSensitiveClassifier:

**CS-1.75wRF-18F.csv** 0.76029
an hour ago by Carlos A
MetaCost 100 BagSizePercent, [0, 1, 1.75, 0] matrix, 10 iterations with 71.468% RandomForest - 5 sentiment 5 emotion 4 personality, number of mentions, retweet and count of links and word